# 职证 CareerProof

## 证据驱动的 AI 职业规划与岗位要求拆解

全国高校 AI Web 开发挑战赛 · 技术文档提交候选稿

版本日期：2026 年 9 月 25 日

学校、参赛组别、团队成员、指导教师和私有仓库访问方式：待参赛者填写。

### 项目定位

学生上传简历与项目材料后，系统先定位可核验的原文件证据，使用 DeepSeek 官方 API 对证据边界进行解释、给出职业方向比较和下一步补证任务。企业可以把自然语言岗位描述拆成带原文引用的要求草稿，并在人工确认后发布。

本系统评价的是材料对岗位要求的支持程度，不认证候选人能力、本人贡献或录用概率。

# 1 真实问题与 Web 产品

传统关键词匹配会把依赖声明、简历自述、空函数和可运行实现混在一起。CareerProof 将结果拆成“已见事实、仍缺证据、下一份可提交材料”，让学生和教师能直接打开原文件核对。

## 学生端链路

上传简历与项目 ZIP/PDF/DOCX/图片 → 等待异步解析 → 查看材料预览 → 按岗位生成证据报告 → 点击引用核对原文件与行号 → 人工采纳、驳回或标记修正 → 生成跨职业规划并比较新版本变化。

## 企业端链路

企业粘贴岗位原文 → AI 提取技能、必要条件、建议权重与原文位置 → 企业逐条核对并确认 → 保存草稿或发布。生成 AI 草稿本身不会创建或公开岗位。

## 主要界面

| 界面 | 核心可见能力 |
| --- | --- |
| 材料中心 | 上传、版本历史、解析预览、原文件与引用行定位 |
| 岗位与任务 | 自然语言岗位拆解、材料选择、外发授权、SSE 阶段状态 |
| 报告与规划 | 证据评级、来源片段、AI 与规则状态、补证建议、人工复核、跨版本变化 |

Web 应用是主要呈现形态；后端承担账号权限、材料解析、模型接入、引用校验与数据持久化。

# 2 技术架构与数据流

Next.js 15、React 19 与 TypeScript 组成前端；FastAPI、SQLAlchemy、PostgreSQL/pgvector 和本地文件存储组成后端。浏览器通过同源代理调用 API，认证 Cookie 保持 HttpOnly。

| 阶段 | 输入与输出 | 关键约束 |
| --- | --- | --- |
| 材料解析 | 简历、项目和扫描图片 → 带版本与行号的文本 | ZIP 静态扫描；不执行上传代码；OCR 置信度需人工核对 |
| 候选检索 | 岗位要求 → 证据片段 | 固定检测器与有界词法候选；可选本地语义文档召回；候选不直接加分 |
| 模型分析 | 必要要求、缺口和片段 → JSON 解释 | 外发同意、脱敏、预算、超时与并发限制 |
| 工具与校验 | 一次受控补检索 → 引用白名单校验 | 只读当前上传索引；伪造引用、越权或非法等级拒绝 |
| 结果展示 | 持久化报告 → SSE/页面/历史 | 异常被动降级；保留规则报告与人工复核 |

## 检索边界

pgvector 中的 local-hash-v1 不是语义 embedding。可选本地 ONNX 模型仅补充文档候选召回；目前缺少足够大的独立召回评测，不声称全职业语义 RAG 能力。

## Agent 边界

模型最多调用一次 retrieve_more_evidence，只能读取当前材料索引中的有限片段。它体现了受控 Function Calling 与工具审计，不宣称通用自主 Agent 或 MCP 集成。

# 3 AI 机制与可信度

AI 不只改写统计摘要。它在规则选出的材料片段内逐项解释岗位要求、指出信息不足、比较不同职业方向并提出可验收的补证任务；企业端还负责从岗位原文生成待确认要求。

## 证据约束评级

统一 1–5 级描述实践证据，但自动 AI 初评目前仅开放到 3 级。相关性、实质操作、完整任务三个判据须顺序成立，且引用必须属于当前要求的白名单。模型不能改变原文件、行号、内容哈希或人工复核结论。

## 从引用到原文

报告与职业规划保留项目版本、文件 ID、行号和可见片段。点击规划引用可打开对应项目文件并高亮引用行。原样重传材料只提示版本变化；只有可见引用片段改变才记为新增证据。

## 多模态能力与边界

本地 RapidOCR 把扫描 PDF 与图片转为带页码、置信度的文本，再进入同一证据校验链。OCR 能识字，但不证明视觉场景理解、作者身份或代码运行结果。

## 安全与故障控制

模型端点和型号固定；外发前按规则脱敏常见直接标识符。没有证据时跳过外部请求；模型限流、超时、结构不合格、非法引用或请求失败时被动保留规则结果，并标明降级原因。

# 4 验收与结果边界

以下为本机仓库与浏览器的工程验收，不等于官方评分或跨人群招聘准确率。

| 验证项 | 已核验结果 |
| --- | --- |
| 后端回归 | 229 项通过；Ruff 检查通过 |
| 前端回归 | 18 项 Node 测试、TypeScript 类型检查、生产构建通过 |
| 真实模型链路 | 合成简历和项目可生成 DeepSeek 规划，比较软件、运营、数据方向并给出补证任务 |
| 浏览器来源跳转 | 规划引用打开 app/00_health.py，并高亮第 6–8 行；相同材料再次生成不误报新证据 |
| 固定难例 | 11 项合成案例：8 项有证据获得模型正文，3 项无证据按生产规则跳过；历史原始 JSON 格式缺陷已留档 |
| 独立语义评测 | 待项目成员以外的评审者签署；不能用引用 ID 合法率代替结论支持率 |

## 技术债与未覆盖项

工作流只有一次受控补检索，没有多轮自主规划；语义文档检索缺大样本召回基准；多模态以 OCR 为主；MCP 未实现。4–5 级需要更强运行或独立验证证据，当前不自动授予。

# 5 运行、隐私与提交状态

## 演示环境

在 Windows + Docker Desktop 环境按 README 的干净环境复现流程安装依赖，并使用 Start-Demo.ps1 或 Start-Demo.cmd 启动。演示只使用 demo/ 合成数据；DeepSeek API Key 仅保存在本机未跟踪的环境文件。

## 隐私原则

学生报告默认只对本人开放，企业不能自动读取；模型调用前展示外发范围并要求主动同意。原图本地 OCR，外部模型只接收有界要求和必要片段。正式演示不得展示真实简历、环境变量或凭据。

## 提交状态与待填信息

| 项目 | 截至本稿状态 |
| --- | --- |
| 源代码 | 本地真实 Git 历史已保留；计划创建 GitHub 私有仓库并按赛事要求提供评审访问 |
| PDF | 本文件为技术候选稿，页数需保持不超过 30；团队、组别、学校和官方模板待确认 |
| 演示视频 | 分镜脚本已有；5–8 分钟、1080p 正式成片尚待录制 |
| 许可 | 暂不公开源码；公开前需根据 PyMuPDF 的双许可约束选择发布许可 |
| 在线演示 | 本机一键启动已具备；公网部署属于可选项 |

追溯材料：README.md；docs/AI职业规划与岗位拆解-20260925.md；docs/DeepSeek可信度验收-20260918.md；docs/受控补检索FunctionCalling.md；docs/OCR多模态能力说明.md；docs/赛前验收清单.md。